

Relazione di Progetto di Machine Learning

Identificazione del Tipo di Rifiuto

Gruppo: 2026_MLinf_gr41 — Gioia Errico, Cutolo Raffaele

1 Motivazione del Dataset e Strategia di Split

Il dataset presenta due problemi principali: un forte sbilanciamento tra le classi (la sola classe *Clothing* rappresenta il 47.1% delle immagini, mentre *Undifferentiated* è solo il 4.5% — un rapporto di $10.5\times$) e un’elevata variabilità nelle condizioni delle immagini. Uno split train/validation puramente casuale rischierebbe di sotto-rappresentare le sotto-classi più piccole (ad es. glass/green, papery/cardboard) nella validazione, rendendo la metrica di validazione inaffidabile proprio dove il modello è più debole.

Abbiamo quindi costruito uno split stratificato 80/20 personalizzato che preserva la proporzione di ogni macro-classe e di ogni sotto-classe in entrambe le parti (ad es. Clothing: 5842 immagini di training / 1460 di validazione, con lo stesso rapporto del 20% applicato anche alle sue sotto-classi “clothes” e “shoes”). In questo modo la nostra Balanced Accuracy di validazione — la metrica ufficiale — è un indicatore affidabile per tutte le 8 classi. Lo split è salvato come `split.csv` e riutilizzato, invariato, in ogni esperimento di questa relazione.

2 Modello di Base (Baseline)

Configurazione. Abbiamo effettuato il fine-tuning di una ResNet18 pre-addestrata su ImageNet, sostituendo l’ultimo layer con una testa lineare a 8 uscite. Tutte le immagini vengono ridimensionate a 224×224 senza cropping: la nostra analisi esplorativa ha mostrato aspect ratio molto variabili, e il cropping avrebbe spesso tagliato via parte dell’oggetto. Nessuna data augmentation in questa fase. Training: SGD (momentum 0.9, weight decay $1e-4$, learning rate 0.01), scheduler cosine-annealing, 15 epoche, Cross-Entropy semplice, mantenendo il checkpoint dell’epoca con la miglior validazione.

Risultati e analisi degli errori. Balanced Accuracy di validazione: **0.967**, con convergenza entro ~ 10 epoche e successivo appiattimento (un primo segnale di overfitting). La classe più debole è *Plastic* (TPR 0.89), confusa principalmente con *Glass* — un errore plausibile, dato che plastica trasparente e contenitori di vetro si somigliano visivamente. Clothing, Organic e Papery sono quasi perfette. Queste osservazioni guidano gli esperimenti successivi.

3 Il Gap di Generalizzazione: una Sonda Out-of-Distribution

Il valore 0.967 va letto con cautela. Le nostre immagini di validazione provengono dalle stesse fotocamere, sfondi e post-processing di quelle di training, quindi questo numero misura quanto bene il modello si adatta a *questo specifico dataset* — non quanto bene riconosca i rifiuti in generale. Il regolamento, invece, specifica che il test set privato è acquisito con fotocamere diverse, in condizioni molto diverse, e possibilmente post-processato. Manteniamo distinti tre numeri lungo tutta la relazione: la *metrica ufficiale* (Balanced Accuracy a 8 classi sul test set privato, a noi incognita), il nostro *punteggio di validazione* (il suo proxy in-distribution) e *RealWaste* (una diagnostica out-of-distribution a 7 classi, introdotta di seguito).

Per verificare se la baseline avesse imparato scorciatoie specifiche del dataset, l’abbiamo valutata — senza alcun ri-addestramento — su **RealWaste**, un dataset pubblico indipendente di immagini di rifiuti. RealWaste è stato usato esclusivamente per la valutazione e non è mai stato aggiunto ai dati di training, nel pieno rispetto della regola che vieta qualsiasi estensione del training set. Non ha la classe Battery, quindi il controllo copre le sette classi in comune, con le sue etichette mappate sulla nostra tassonomia.

Risultato: la Balanced Accuracy crolla da 0.967 a **0.455**. Il calo è molto disomogeneo: Clothing resta alta, Organic e Plastic scendono bruscamente, e Undifferentiated diventa quasi casuale (TPR 0.04) nonostante sia una delle classi migliori in-distribution (0.976). La matrice di confusione su RealWaste mostra un pattern sistematico: la colonna Clothing funge da *attrattore* — gli errori di quasi ogni classe

finiscono lì. Individuiamo due cause concomitanti: (i) Clothing rappresenta il $\sim 47\%$ del training set, quindi una loss non pesata dà al modello un forte prior verso di essa, e quando il modello è incerto ricade sulla classe più frequente; (ii) Clothing è visivamente eterogenea (indumenti e scarpe di qualsiasi colore e forma), quindi occupa una regione ampia dello spazio delle feature e funziona come un contenitore raccogli-tutto.

Verifica di stabilità (cross-validation a 5 fold). Per verificare che il punteggio di validazione non sia frutto della fortuna di un singolo split, abbiamo eseguito una CV stratificata a 5 fold con la stessa identica ricetta: 0.960 ± 0.005 (il fold 1 coincide con il nostro split e riproduce 0.965), con ogni TPR per classe stabile (dev. std < 0.022). La stima in-distribution è quindi affidabile — e di conseguenza il crollo OOD non può essere rumore: è un effetto reale dello shift di distribuzione. *Questo gap è il risultato centrale del progetto:* l’obiettivo di tutto ciò che segue è chiuderlo, non gonfiare ulteriormente un punteggio di validazione già saturo. Usiamo RealWaste come lente diagnostica deliberatamente pessimistica, insieme a — non al posto di — la metrica in-distribution. Un avvertimento sul suo valore assoluto: due mapping di etichette sono rumorosi (Textile Trash→Clothing, Miscellaneous→Undifferentiated), quindi il numero di RealWaste va usato soprattutto per confrontare i modelli piuttosto che come accuratezza assoluta; poiché il mapping è identico per tutti i run, i confronti restano comunque equi.

4 Piano Sperimentale

Variamo un solo fattore alla volta. Per prima cosa selezioniamo la *ricetta di training* (data augmentation e gestione dello sbilanciamento) su una ResNet18 fissa, perché queste contromisure affrontano proprietà del dataset, non di un modello specifico. Solo una volta fissata la ricetta migliore confrontiamo i *backbone* sotto quella ricetta congelata, poiché una classifica ottenuta con una ricetta più debole potrebbe non trasferirsi. Tutti gli esperimenti sulla ricetta condividono lo stesso split, ottimizzatore, schedule, epoche e seed; l’unica variazione è il fattore sotto esame, quindi ogni differenza è attribuibile a quel solo fattore.

5 Esperimento 1: Data Augmentation Fotometrica

Ipotesi. Se la baseline si basa su indizi di acquisizione di basso livello — bilanciamento del colore, nitidezza, artefatti JPEG, rumore del sensore — specifici di questo dataset, allora perturbare proprio questi indizi durante il training dovrebbe costringere il modello a ignorarli, facendo salire il punteggio OOD anche se la validazione resta invariata.

Progettazione. Un solo parametro, AUG_LEVEL, applicato solo al training set: **light** = flip orizzontale, piccole rotazioni, ColorJitter lieve; **strong** = **light** + RandomGrayscale, GaussianBlur, compressione JPEG simulata, jitter più forte, RandomErasing.

Modello	Validazione (in-distr.)	RealWaste (OOD)
baseline	0.967	0.455
light	0.968	0.459
strong	0.954	0.432

Tabella 1: Balanced Accuracy sui due insiemi. RealWaste è a 7 classi (senza Battery).

Lettura. L’ipotesi non è confermata. **light** non cambia nulla di reale: il guadagno OOD (+0.004) è sotto il rumore di CV di ± 0.005 . **strong** è realmente peggiore su entrambi gli insiemi (OOD -0.023 , circa 4 volte il rumore). In-distribution, **strong** danneggia soprattutto le classi piccole e difficili (Plastic $0.91 \rightarrow 0.84$): grayscale insieme a jitter e blur pesanti cancellano proprio gli indizi di colore e lucentezza che distinguono plastica, vetro e organico. Su RealWaste l’effetto è una redistribuzione — alcune classi migliorano (glass $0.46 \rightarrow 0.66$), altre crollano (plastic $0.35 \rightarrow 0.18$) — che nel complesso è negativa.

Conclusione. L’intensità dell’augmentation si comporta come una U rovesciata: un po’ è innocuo, troppo distrugge il segnale. Ancora più importante: la corruzione fotometrica simula *come è stata scattata la foto*, non *come appare l’oggetto*: lo shift reale verso RealWaste riguarda l’aspetto e il contesto dell’oggetto (foto prodotto pulite vs. rifiuti reali sporchi su sfondi disordinati). Manteniamo **light** come

default innocuo, teniamo in riserva la famiglia geometrica (Sezione 7), e rimandiamo deliberatamente alla Sezione 10 la parte centrale, non ancora testata, della curva di intensità — una dose lieve e calibrata.

6 Esperimento 2: Gestione dello Sbilanciamento delle Classi

Ipotesi. Se il prior verso Clothing individuato nella Sezione 3 è una causa principale del gap, neutralizzarlo dovrebbe far salire il TPR OOD delle classi minoritarie. In-distribution non ci aspettiamo alcun cambiamento per costruzione, perché la Balanced Accuracy pesa già tutte le classi allo stesso modo.

Progettazione. Baseline interamente congelata, deliberatamente *senza* augmentation (così da non mescolarsi con l’effetto in esame). Un solo fattore, il meccanismo di ribilanciamento: **weighted_loss** = Cross-Entropy con pesi per classe inversamente proporzionali alla frequenza della classe; **sampler** = WeightedRandomSampler che sovracampiona le classi minoritarie in modo che ogni batch sia approssimativamente bilanciato.

Classe	baseline (OOD)	weighted_loss (OOD)	sampler (OOD)
clothing	0.899	0.874	0.893
glass	0.462	0.505	0.367
metal	0.511	0.546	0.518
organic	0.388	0.401	0.115
papery	0.534	0.483	0.662
plastic	0.349	0.296	0.296
undifferentiated	0.042	0.067	0.024
Balanced Accuracy OOD	0.455	0.453	0.411

Tabella 2: TPR OOD per classe su RealWaste. In-distribution tutte le varianti sono indistinguibili dalla baseline (0.961–0.962 vs 0.960 ± 0.005).

Lettura. **Weighted_loss** fa meccanicamente ciò per cui è stato progettato — l’attrattore Clothing si indebolisce e diverse classi minoritarie guadagnano — ma i guadagni sono annullati dalle perdite su Plastic e Papery: netto $0.453 \approx 0.455$. Il ri-pesamento sposta il confine decisionale, ma opera su feature che sono già sbagliate out-of-distribution: cambia *in quale classe sbagliata* cade un campione, non *se le sue feature siano corrette*. **Sampler** è chiaramente peggiore (0.411), e il motivo è istruttivo: senza augmentation, il sovracampionamento mostra al modello le stesse poche immagini minoritarie molte volte, amplificando la memorizzazione delle loro scorciatoie di acquisizione; Organic crolla ($0.388 \rightarrow 0.115$).

Conclusione. Il ribilanciamento non chiude il gap. Una lezione da portare avanti: insieme all’Esperimento 1, la diagnosi converge; il fattore dominante è lo shift nell’aspetto e nel contesto dell’oggetto, che né l’augmentation fotometrica né il ribilanciamento riescono a toccare.

7 Esperimento 3: Augmentation Geometrica e Strutturale

Ipotesi. Le trasformazioni geometriche cambiano *come l’oggetto è inquadrato* — la sua posizione, scala e porzione visibile — piuttosto che come la foto è stata scattata. Se lo shift reale riguarda l’inquadratura e il contesto, questa famiglia (tenuta in riserva dall’Esperimento 1) dovrebbe essere quella che aiuta.

Progettazione. Il riferimento qui è **light**, non la baseline nuda, così il fattore isolato è la perturbazione geometrica. **geo_rrc** = **light** + RandomResizedCrop; **geo_rrc_cutmix** = lo stesso + CutMix, che incolla una parte di un’immagine su un’altra e mescola le etichette proporzionalmente. La trasformazione di validazione resta invariata, mantenendo tutti i numeri comparabili.

Configurazione	Validazione (in-distr.)	RealWaste (OOD)
baseline	0.967	0.455
light (riferimento)	0.968	0.459
geo_rrc (light + RRC)	0.964	0.426
geo_rrc + CutMix	0.965	0.331

Lettura. Non confermata — il risultato negativo più netto finora. La validazione resta invariata (~ 0.965 ovunque), mentre l’OOD non supera mai **light**: RRC lo abbassa leggermente, e CutMix lo abbassa bruscamente. Per classe, CutMix fa crollare Organic ($0.447 \rightarrow 0.055$) e Plastic, mentre rende l’attrattore Clothing ancora più forte ($0.855 \rightarrow 0.890$): CutMix insegna previsioni miscelate e a bassa confidenza, e out-of-distribution quell’incertezza si risolve verso la classe dominante — il pattern di fallimento della Sezione 3, amplificato.

Conclusione. Preso alla lettera, questo completa un quadro netto: augmentation fotometrica, ribilanciamento e ora anche la geometria falliscono tutti su RealWaste. Ci fermiamo però volutamente un attimo prima di questa conclusione, per un motivo preciso: finora ogni giudizio si è basato su un solo metro, RealWaste, scelto appositamente perché è un caso pessimistico. La traccia ci avverte che ci saranno fotocamere e condizioni diverse, ma non ci dice *quanto sarà forte* questo cambiamento; se ci basassimo solo sulla severità di RealWaste, rischieremmo di scartare una contromisura che invece, con uno shift più leggero, avrebbe funzionato bene. Per questo nella Sezione 8 costruiamo un metro di valutazione tarato proprio sulla traccia.

8 Selezione della Ricetta tramite uno Stress Test Interno Calibrato

Motivazione. La validazione pulita non riesce a separare le ricette (tutte entro ± 0.005 , perché è satura); RealWaste potrebbe esagerare la difficoltà. Ci serve un terzo metro di giudizio intermedio: le stesse immagini ed etichette della nostra validazione, ma presentate in condizioni più dure e simili alla traccia, a più di un livello di severità.

Metodo. Costruiamo un *hard-validation set* applicando corruzioni moderate e realistiche alle immagini di validazione: cambi di inquadratura e scala (crop/zoom, piccole rotazioni), degrado della risoluzione, ricompressione JPEG, jitter fotometrico lieve e rumore leggero del sensore, a due intensità (**mild**, **moderate**). Due proprietà mantengono il confronto equo e nel rispetto delle regole: nessun modello viene ri-addestrato — i checkpoint salvati sono valutati così come sono; e il training set non viene mai toccato — solo la valutazione è sottoposta a stress.

Ricetta	clean-val	hard-val (mild)	hard-val (moderate)	RealWaste (severa)
baseline (CE)	0.967	0.937	0.828	0.455
light	0.968	0.932	0.828	0.459
weighted_loss	0.961	0.936	0.802	0.453
geo_rrc (light + RRC)	0.964	0.946	0.860	0.426
geo_rrc + CutMix	0.965	0.938	0.871	0.331

Prima lettura. La classifica dipende dalla severità: pari a shift nullo, **geo_rrc** guida sotto mild/moderate, e l’ordine si inverte a RealWaste. Presa alla lettera questa lettura ribalterebbe la Sezione 7 e incoronerebbe **geo_rrc** come la ricetta migliore. Questa è la conclusione che avevamo tratto nella nostra prima stesura. Nelle prossime righe dimostreremo, al contrario, che la realtà è ben diversa.

Un bias nascosto (confondimento) nella sonda. Prima di impegnarci sulla scelta, ci siamo chiesti *perché* **geo_rrc** fosse in testa — e abbiamo scoperto che il confronto era prematuro. Il punteggio hard-validation aggregato è dominato dalle perturbazioni di inquadratura e scala, che sono esattamente la trasformazione su cui **geo_rrc** si allena (RandomResizedCrop): la sonda premia la ricetta per essere robusta alla propria stessa augmentation, il che è quasi circolare. L’aggregato inoltre sottopesa l’asse dell’acquisizione (quello che la traccia nomina per primo: “fotocamere diverse, condizioni molto diverse, post-processing”) e non isola mai le due condizioni che la traccia menziona esplicitamente, rimozione dello sfondo e cambio di risoluzione.

Decomposizione allineata alla traccia. Abbiamo ricostruito la sonda come quattro famiglie di perturbazioni allineate una-a-uno con la traccia — *geometrica* (inquadratura/scala), *acquisizione* (blur, JPEG, jitter, rumore), *sfondo* (soggetto isolato su un campo neutro, “sfondo rimosso”) e *risoluzione* — valutate separatamente, alle stesse intensità, con lo stesso protocollo equo. Prima di leggere i numeri

abbiamo fissato una regola di selezione: l’asse primario è l’acquisizione; una soglia minima di robustezza richiede che la ricetta scelta non sia ultima in nessuna famiglia; il clean-val deve stare entro ± 0.005 dal migliore; i pareggi si risolvono sulla media delle quattro famiglie.

Ricetta	clean-val	geometrica	acquisiz.	sfondo	risoluz.	media 4 fam.
light	0.968	0.957	0.920	0.887	0.932	0.924
strong	0.954	0.946	0.917	0.878	0.943	0.921
baseline (CE)	0.967	0.956	0.913	0.886	0.939	0.924
weighted_loss	0.961	0.956	0.912	0.844	0.927	0.910
sampler	0.962	0.951	0.909	0.857	0.929	0.912
geo_rrc	0.957	0.957	0.893	0.828	0.927	0.901
geo_rrc + CutMix	0.965	0.961	0.871	0.930	0.918	0.920

Tabella 3: Bal.Acc a 8 classi per famiglia, mediata su mild e moderate. Ricette ordinate secondo l’asse acquisizione; la ricetta selezionata (light) è evidenziata.

Lettura. La decomposizione ribalta la prima lettura. Il vantaggio di **geo_rrc** era confinato alla sua stessa famiglia “di casa” — dove non batte nemmeno **light** (0.957 vs 0.957) — mentre sull’acquisizione è tra i peggiori (0.893) ed è ultimo sulla media di tutte le famiglie e più basso sullo sfondo, non superando la soglia minima di robustezza. **light** è primo sull’acquisizione (0.920) e primo sulla media di tutte le famiglie (0.924), mai peggiore di alcun concorrente su nessun asse, con il miglior clean-val; la sonda indipendente RealWaste conferma ($\text{light } 0.459 > \text{geo_rrc } 0.426$).

Decisione. Adottiamo **light**. Rigettiamo **geo_rrc** (il suo vantaggio era un artefatto della sonda distorta), CutMix (ultimo sull’acquisizione, 0.331 su RealWaste) e **weighted_loss** (mantenuto solo come diagnostica della Sezione 6). Anche **light**, tuttavia, si ferma a 0.920 sull’acquisizione — la sua famiglia più debole e l’asse primario della traccia — lasciando un margine chiaro che la Sezione 10 andrà a colmare. Sotto acquisizione moderata le classi più deboli sono Metal (~ 0.75) e Plastic (~ 0.86): diventano gli obiettivi del confronto tra backbone. *Lezione di metodo: un test di robustezza è affidabile solo se ciò che perturba è indipendente da ciò su cui il modello è stato addestrato.*

9 Confronto tra Architetture

9.1 Due assi, risolti in sequenza

Ricetta e architettura sono assi indipendenti, ed esplorare la loro combinazione completa non è né necessario né sostenibile in termini di tempo. Dopo aver fissato la ricetta (**light**), fissiamo ora l’architettura, addestrando ogni candidato con la ricetta identica: ogni differenza sarà quindi attribuibile alla sola architettura.

9.2 Cosa significa qui “modello migliore”

L’accuratezza pulita è satura (0.96–0.98 per ogni scelta ragionevole) e porta quasi nessun segnale; l’accuratezza ancora in gioco è quella sotto shift. Inoltre il compito valuta esplicitamente un trade-off a tre vie: Balanced Accuracy, memoria GPU in fase di test (meno è meglio) e frame rate (più è meglio). Quindi: selezionare principalmente sull’accuratezza hard-validation, trattare la validazione pulita come un controllo di sanità, e preferire il miglior punto sulla frontiera — un modello più pesante è giustificato solo se converte il suo costo in accuratezza robusta, specialmente su Metal e Plastic.

9.3 Candidati ed esclusioni

Quattro backbone torchvision pre-addestrati su ImageNet, scelti per coprire lo spettro di capacità: ResNet18 (11.7M parametri — il titolare veloce e leggero), RegNetY-1.6GF (eccellente rapporto accuratezza/latenza GPU reale), EfficientNetV2-S (capacità maggiore, progettato per sfruttare bene la GPU) e ConvNeXt-Tiny (28M, design moderno, nativo a 224×224). Esclusi, con le relative motivazioni: MobileNetV3 — non sfrutta al meglio la GPU, quindi pur essendo un modello leggero risulta lento nell’elaborare le immagini (spesso più lento di ResNet18, al contrario di quanto richiede il progetto); EfficientNetV2-M — è troppo grande e complesso per le poche immagini a disposizione, con il rischio di overfitting, ed è progettato per immagini troppo grandi che il nostro sistema non riesce a gestire.

9.4 Protocollo di confronto equo

Tutto tranne il backbone resta identico alla configurazione `light` congelata: stesso `split.csv`, 224×224 , stessa augmentation, Cross-Entropy semplice, 15 epoche, schedule cosine, seed 1234, checkpoint alla epoca migliore, stessa trasformazione di validazione deterministica, fine-tuning completo. Ottimizzatore: SGD per tre backbone, AdamW per ConvNeXt-Tiny, notoriamente difficile da fine-tunare con SGD semplice — confrontiamo le architetture al loro meglio piuttosto che penalizzarne una per il motivo sbagliato; segnaliamo l’assenza di un’analisi approfondita del learning rate per backbone come limite, poiché, avendo già ottenuto la convergenza su ResNet, non lo abbiamo verificato sulle altre architetture. Rumore di fondo: run ripetuti della stessa identica configurazione differiscono di ~ 0.007 (non-determinismo della GPU), coerente con il rumore di CV di ± 0.005 ; la regola di decisione deve rispettarlo.

9.5 Il budget di memoria di training da 5 GB

A un batch fisico di 64, due backbone superano il limite di 5 GB in training e RegNetY lo rispetta solo di misura. Ridurre il batch solo per i modelli pesanti cambierebbe la dinamica di ottimizzazione e comprometterebbe l’equità del confronto. Risolviamo entrambi i problemi con il *gradient accumulation*: il batch effettivo resta 64 per tutti, e viene adattato solo il micro-batch fisico — la ricetta di ottimizzazione è identica, cambia solo la velocità. A seguito di tale modifica, tutti i run sono stati verificati sotto i 5 GB dalle letture del picco di memoria.

Backbone	VRAM @ batch 64	Entro i 5 GB?	Micro-batch $\times$ accum.
ResNet18	~ 1.94 GB	sì	64×1
RegNetY-1.6GF	~ 4.92 GB	al limite	32×2
ConvNeXt-Tiny	~ 7.43 GB	no	32×2
EfficientNetV2-S	~ 10.64 GB	no	16×4

9.6 Metriche e regola di decisione pre-registrata

Per ogni backbone misuriamo: Bal.Acc clean-val (solo controllo di sanità); Bal.Acc hard-val (mild + moderate, stessa pipeline allineata alla traccia per tutti — il criterio primario); memoria GPU in fase di test (picco durante un forward pass; deve restare sotto i 4 GB); frame rate. Regola di decisione, fissata prima di leggere i risultati: vince il backbone con la media hard-val più alta; se la differenza di prestazioni è minima, con un divario $\Delta \leq 0.01$ (circa il doppio della normale variazione tra le diverse esecuzioni), lo consideriamo un pareggio e vince il modello più efficiente (dando priorità prima alla velocità dei frame e poi allo spazio in memoria); in caso di ulteriore parità, la scelta ricade sul modello di partenza più semplice (ResNet18).

9.7 Controllo di sanità (validazione pulita)

Backbone	clean-val Bal.Acc	Metal TPR	Plastic TPR	Pesi
RegNetY-1.6GF	0.985	0.974	0.965	~ 42 MB
EfficientNetV2-S	0.984	0.961	0.954	~ 82 MB
ConvNeXt-Tiny	0.977	0.987	0.954	~ 111 MB
ResNet18	0.972	0.942	0.919	~ 45 MB

Tutti e quattro i training sono validi. Dalla tabella appena riportata, però, emergono due osservazioni: i modelli più grandi superano ResNet18 con un margine inferiore alle aspettative (poiché il dataset senza perturbazioni appiattisce le differenze e non giustifica, da solo, il costo di un modello più pesante), e la capacità di calcolo aggiuntiva va visibilmente a beneficio delle classi più difficili (RegNetY alza la precisione su Plastic da 0.919 a 0.965; ConvNeXt porta Metal a 0.987) — un segnale incoraggiante, ma la sua reale tenuta di fronte a dati alterati (sotto shift) verrà verificata nel passaggio successivo.

9.8 Confronto di robustezza e selezione

Backbone	Hard-val (media)	Mem. test (GB)	Frame rate (fps)	Metal TPR (shift)	Plastic TPR (shift)
EfficientNetV2-S	0.964	0.47	280	0.831	0.861
RegNetY-1.6GF	0.963	0.30	356	0.831	0.827
ConvNeXt-Tiny	0.947	0.53	200	0.870	0.832
ResNet18	0.934	0.29	1186	0.779	0.856

Il guadagno di capacità sopravvive — e cresce — sotto shift. Tutti e tre i backbone più grandi battono ResNet18 per più del rumore di fondo, e per più di quanto avvenga sull'insieme pulito (RegNetY: +0.014 su clean, +0.029 su hard): la capacità extra si converte in accuratezza robusta, l'unica giustificazione ammessa dalla Sezione 9.2.

Applicando la regola di decisione: EfficientNetV2-S (0.9637) contro RegNetY (0.9625) dà $\Delta = 0.0012$ — un pareggio statistico — quindi la decisione passa all'efficienza, dove RegNetY domina su entrambi gli assi (356 contro 280 img/s; 0.30 contro 0.47 GB) con circa la metà dei parametri. Quindi, a parità di accuratezza, RegNetY risulta più efficiente rispetto a EfficientNetV2-S: **RegNetY-1.6GF è quindi selezionato come backbone vincente**. La classifica dei primi due è identica se ci si basa solo sull'asse acquisizione invece che sulla media delle quattro famiglie, quindi la scelta non dipende dal criterio. Tutti i candidati sono ben sotto il budget di 4 GB in test: la memoria non è l'asse vincolante; lo sono robustezza e throughput.

Limite onesto: RegNetY migliora chiaramente Metal nella condizione più dura (0.779 $\rightarrow$ 0.831), ma Plastic in quella stessa condizione (0.827) resta marginalmente sotto ResNet18 (0.856) nonostante un ampio vantaggio su clean — Plastic sotto acquisizione dura resta il punto debole residuo. ConvNeXt-Tiny è dominato (meno robusto, più pesante, più lento); ResNet18 resta il ripiego per la pura velocità (1186 img/s), ma il suo deficit di robustezza supera il rumore di fondo.

9.9 Augmentation in fase di test (TTA)

Come rifinitura applicata solo nella fase finale, ogni immagine viene valutata insieme alla sua versione specchiata orizzontalmente e si fa la media dei due risultati. Sul nostro test più severo questo fa salire il punteggio da 0.9625 a 0.9645: una variazione minima che rientra nel normale rumore statistico, quindi non lo dichiariamo come un vero miglioramento. Lo manteniamo comunque nel codice definitivo perché non comporta rischi: specchiare l'immagine non cambia l'oggetto (una bottiglia specchiata è sempre una bottiglia), quindi non può rovinare previsioni già corrette; l'unico prezzo da pagare è sulla velocità (che scende da $\sim 356 \rightarrow \sim 178$ img/s, restando comunque ampiamente nei limiti richiesti, mentre la memoria rimane ferma a 0.30 GB). È un margine di sicurezza aggiuntivo, non un reale guadagno prestazionale.

10 Rafforzare l'Asse Primario: la Ricetta `acq_mild`

Motivazione. `light` si ferma a 0.920 sull'acquisizione — l'asse primario della traccia e la sua stessa famiglia più debole. La Sezione 5 aveva individuato l'estremo dannoso della curva di intensità (**strong**) ma non ne aveva mai testato la parte centrale: una dose lieve e calibrata di perturbazione di tipo acquisizione, abbastanza forte da rompere le scorciatoie di cattura della Sezione 3, ma abbastanza leggera da preservare gli indizi di colore e lucentezza. Ipotizziamo che questa dose si collochi vicino al picco della U rovesciata.

Progettazione. `acq_mild` = `light` + un blocco di acquisizione lieve (blur gaussiano leggero, ricompressione JPEG simulata lieve, piccolo jitter fotometrico, rumore di sensore leggero), applicato solo al training set; tutto il resto è congelato come in ogni esperimento sulla ricetta. Restiamo sul banco di prova ResNet18 per comparabilità; il backbone scelto viene ri-addestrato sotto `acq_mild` nella Sezione 12.

Ricetta	clean-val	geom.	acquisiz.	sfondo	risoluz.	media 4 fam.	RealWaste
light	0.968	0.957	0.920	0.887	0.932	0.924	0.459
acq_mild	0.965	0.961	0.956	0.867	0.955	0.935	0.492

Risultato. `acq_mild` fa salire l’asse primario da 0.920 a **0.956**, guida la media di tutte le famiglie, è il migliore sulla risoluzione e pareggia il migliore sulla geometria, senza alcun costo in-distribution. Sulla sonda indipendente RealWaste raggiunge **0.492** — il migliore dell’intero studio, +0.033 rispetto a `light` (~ 6 volte il rumore). Il pattern per classe è esattamente quello che una buona ricetta dovrebbe produrre: l’attrattore Clothing si indebolisce ($0.824 \rightarrow 0.777$) e la maggior parte delle classi minoritarie guadagna (organic $0.336 \rightarrow 0.482$, glass, plastic, papery), con Metal come unica regressione. Fondamentalmente, questo è un guadagno netto, non una redistribuzione che si annulla come in `strong` o `weighted_loss`.

Autoverifica per il bias della Sezione 8. Per rigore metodologico dobbiamo accogliere questo risultato con cautela: `acq_mild` viene addestrato su disturbi di acquisizione e valutato, in parte, sulla stessa categoria — una quasi-circularità simile a quella che aveva sovrastimato `geo_rrc`. Applicando lo stesso test per eliminare questa distorsione (escludendo la categoria “di casa”), la verifica interna mostra un pareggio (0.928 contro 0.926). La scelta finale si basa quindi su due prove che questa distorsione non può spiegare: il vantaggio nella categoria risoluzione (su cui `acq_mild` non ha fatto addestramento) e, soprattutto, l’incremento di +0.033 ottenuto su RealWaste, un dataset del tutto indipendente.

Riconciliazione con l’Esperimento 1: nessuna contraddizione — la Sezione 5 aveva trovato il tratto discendente della U rovesciata (`strong` esagera), questa sezione ne trova il picco: il segno dell’effetto dipende dalla dose.

Una descrizione più precisa del gap. Il gap ha una componente di acquisizione recuperabile, che l’augmentation calibrata riconquista (RealWaste $0.455 \rightarrow 0.492$), ma non è chiuso ($0.492 \ll 0.965$): il residuo dominante è lo shift di oggetto/contesto tra foto prodotto pulite e rifiuti del mondo reale, fuori dalla portata di qualsiasi leva lato-dati da noi trovata.

10.1 Due estensioni che falliscono

`acq_mild` + RandomErasing. Ipotesi: un’augmentation da occlusione dovrebbe aiutare la condizione “oggetti multipli / viste parziali”. Risultato: nessun guadagno sulle famiglie geometrica o sfondo, e RealWaste scende $0.492 \rightarrow 0.444$ (~ 9 volte il rumore). Meccanismo: su un training set dominato da Clothing, cancellare patch spinge il modello a “riempire” verso il prior maggioritario — l’attrattore si rigonfia ($0.777 \rightarrow 0.836$) mentre le classi minoritarie più deboli vengono schiacciate (organic $0.482 \rightarrow 0.306$, plastic $0.465 \rightarrow 0.330$). *Rigettata.*

`acq_mild` + loss pesata per classe. Ipotesi: ora che `acq_mild` ha migliorato la rappresentazione, il ri-pesamento potrebbe finalmente avere effetto. Risultato: l’acquisizione scende ($0.956 \rightarrow 0.948$), lo sfondo crolla ($0.867 \rightarrow 0.829$), RealWaste diminuisce $0.492 \rightarrow 0.476$. Il ri-pesamento scambia di nuovo TPR tra classi con una perdita netta — confermando, a grana più fine, che Plastic e Metal sono deboli sotto shift per motivi di aspetto, non di frequenza. *Rigettata.*

Cosa stabiliscono insieme questi risultati negativi. L’unico intervento con un guadagno OOD reale e non redistributivo è quello che migliora *ciò che le feature codificano* (`acq_mild`). Ogni intervento sul confine decisionale, sul prior di campionamento, o sull’incollare/cancellare patch — loss pesata, sampler, CutMix, RandomErasing — redistribuisce il TPR con un netto pari a zero o negativo, oppure rigonfia l’attrattore maggioritario. **Decisione: `acq_mild` viene congelata come ricetta finale.**

11 Robustezza alla Molteplicità di Oggetti della Stessa Classe

La traccia elenca foto con più oggetti della stessa classe. Verifichiamo piuttosto che addestrare per questo, per due motivi: i nostri backbone terminano con un global average pooling, quindi più istanze di una classe rinforzano un unico segnale aggregato invece di competere tra loro; e la molteplicità è già presente nei dati di training (batterie in coppia, frammenti di vetro, casse di banane, pile di riviste). Protocollo (solo valutazione, nessun ri-addestramento): dalle immagini di validazione componiamo mosaici 2×2 e 3×3 della stessa classe su un campo bianco e valutiamo la ricetta vincitrice (ResNet18 `acq_mild`) contro il riferimento a oggetto singolo.

	singolo	2×2	3×3
Balanced accuracy	0.965	0.925	0.694
clothing	0.997	0.775	0.150
metal	0.935	0.875	0.375
plastic	0.902	0.825	0.475
battery / glass / papery / undiff.	≥0.97	≥1.00	≥0.93

Lettura. Sotto molteplicità lieve (2×2) il modello è sostanzialmente invariante, e le classi nativamente multiple sono perfette. Il calo a 3×3 confonde due effetti: la molteplicità vera e propria e un grave artefatto di scala — nove oggetti affiancati in un frame di 224 px rimpiccioliscono ciascuna istanza di più volte. Infatti il crollo si concentra esattamente nelle classi che richiedono dettaglio locale fine (clothing 0.15, metal, plastic), mentre le classi riconoscibili dalla texture restano alte (papery 1.00, glass 0.975). La condizione realistica — pochi oggetti della stessa classe che riempiono il fotogramma — corrisponde al regime robusto 2×2 ; il limite legato a oggetti piccoli/bassa risoluzione è registrato come un punto debole noto coerente con la famiglia risoluzione, non come un fallimento di molteplicità. Grazie al design condiviso con global average pooling, ci aspettiamo la stessa invarianza sul backbone consegnato.

12 Modello Finale e Conclusioni

Il sistema consegnato è una **RegNetY-1.6GF sottoposta a fine-tuning sotto acq_mild**, scelta in tre fasi pre-registrate — prima la famiglia di ricetta (**light**, Sezione 8), poi l’architettura (RegNetY, Sezione 9), infine il rafforzamento della ricetta (**acq_mild**, Sezione 10) — ciascuna giudicata sulla sonda de-confondita e allineata alla traccia, non sul punteggio clean saturo. Trasferito al backbone scelto, **acq_mild** raggiunge una Balanced Accuracy hard-validation di **0.971** (clean 0.980) e RealWaste **0.582**, con 0.30 GB di memoria in test e ~ 178 img/s — confermando che il guadagno sull’asse acquisizione si trasferisce all’architettura, come previsto dalla separabilità ricetta/architettura della Sezione 4. La `predict()` dello script di test carica `regnety16gf_acq_mild.pth`, applica lo stesso Resize(224) deterministico + normalizzazione ImageNet usati in tutto lo studio, e media la previsione sull’input e sul suo flip orizzontale (TTA, Sezione 9.9).

12.1 Profondità del fine-tuning: congelamento parziale

Una leva motivata era rimasta non testata: addestrare meno layer, per proteggere le feature pre-addestrate dalla distorsione. La testiamo direttamente sul modello consegnato, cambiando un solo fattore (quali layer vengono aggiornati): **full_ft** (consegnato, tutti i layer), **shallow_freeze** (stem + blocchi 1–2 congelati, $\sim 4\%$ dei parametri), **mid_freeze** (anche il blocco 3, $\sim 57\%$), **lp_ft** (3 epoche solo sulla testa, poi fine-tuning completo).

Variante	clean-val	acquisizione	hard-val media	RealWaste (OOD)
full_ft (consegnato)	0.980	0.973	0.971	0.582
shallow_freeze	0.982	0.973	0.972	0.604
mid_freeze	0.971	0.948	0.950	—
lp_ft	0.975	0.968	0.964	—

Tabella 4: **mid_freeze** e **lp_ft** sono risultate dominate sulla sonda in-distribution e non sono state portate alla sonda OOD.

Lettura e decisione. Sull’asse di selezione, **shallow_freeze** e **full_ft** pareggiano ($\Delta = 0.0014 \ll 0.01$) e sono identiche su entrambi gli assi di efficienza. **mid_freeze** regredisce chiaramente — il blocco 3 deve adattarsi al dominio dei rifiuti — e **lp_ft** non porta benefici: le due delimitano la profondità di congelamento utile da entrambi i lati. L’unico vantaggio di **shallow_freeze** è su RealWaste (0.604 contro 0.582, sopra il rumore), coerente con la conservazione delle feature ImageNet generiche di basso livello. La nostra regola pre-registrata risolve il pareggio a favore del titolare, **full_ft**: RealWaste è stata una sonda di conferma per tutto lo studio, mai un criterio di selezione, e promuoverla ora romperebbe la stessa disciplina che rende affidabili le decisioni precedenti. **shal-**

`low_freeze` viene registrata come la candidata più forte per un'iterazione futura — un guadagno di robustezza a costo di inferenza zero.

12.2 Un controllo post-hoc: opzione di rigetto basata sulla confidenza

Poiché Undifferentiated è la classe più esposta allo shift, abbiamo testato un affinamento che non richiede ri-addestramento: reindirizzare una previsione a Undifferentiated ogni volta che la probabilità softmax massima (dopo TTA) scende sotto una soglia τ . Due soglie sono state pre-registrate ($\tau = 0.5$, $\tau = 0.7$) invece di essere esplorate a tappeto, perché esplorare τ sulla stessa sonda usata per riportare le prestazioni sarebbe di per sé un tuning sull'insieme di valutazione (overfitting sul validation set).

Variante	media hard-val	acquisizione	Metal TPR	Plastic TPR	Undiff. TPR
nessun rigetto	0.9724	0.9746	0.9481	0.9364	0.9496
$\tau = 0.5$	0.9701	0.9726	0.9351	0.9191	0.9640
$\tau = 0.7$	0.9601	0.9614	0.8961	0.8844	0.9712

Entrambe le soglie scambiano TPR di Metal/Plastic per TPR di Undifferentiated — lo stesso pattern a somma zero sul confine decisionale già visto prima. $\tau = 0.7$ supera chiaramente la soglia minima pre-registrata; $\tau = 0.5$ resta entro il limite ma guadagna troppo poco (+0.014) per essere reale. *Rigettata*: `predict()` viene consegnata senza — un'ulteriore conferma che gli interventi sul confine decisionale redistribuiscono il TPR invece di crearlo.

Messaggi chiave da portare a casa

- **La validazione in-distribution era satura e poco informativa:** la competizione si decide sull'accuratezza robusta sotto shift di distribuzione, che abbiamo sondato con uno stress test interno allineato alla traccia, usato insieme alla lente deliberatamente pessimistica di RealWaste.
- **Una sola leva lato-ricetta ha prodotto un guadagno OOD reale e non redistributivo:** l'augmentation di acquisizione lieve e calibrata (`acq_mild`), che porta RealWaste da 0.455 a 0.492 e l'asse primario della traccia da 0.920 a 0.956, indebolendo l'attrattore Clothing. L'effetto dipende dalla dose: una corruzione aggressiva esagera e danneggia; la dose calibrata aiuta.
- **Ogni intervento sul confine decisionale o sul prior è fallito** — ri-pesamento della loss (da solo e su `acq_mild`), oversampling, CutMix, RandomErasing e l'opzione di rigetto — redistribuendo il TPR con un netto pari a zero o negativo, oppure rigonfiando l'attrattore maggioritario. La leva è ciò che le feature codificano, non dove si trova il confine; il residuo dominante è lo shift di oggetto/contesto, che `acq_mild` raggiunge solo in parte.
- **Il nostro risultato metodologico più istruttivo è un errore di valutazione nascosto che abbiamo scoperto nel nostro stesso sistema di test:** una valutazione di stress globale finiva per premiare il metodo addestrato proprio su quel tipo di trasformazione (`geo_rrc`). Suddividere il test in categorie separate in base alle richieste del progetto, seguendo una regola stabilita in anticipo, ha ribaltato la scelta finale — un test di robustezza è affidabile solo se c'è una reale indipendenza tra i disturbi usati per valutare e i dati su cui il modello si è allenato.
- **Una capacità maggiore si converte in accuratezza robusta, non solo pulita:** il vantaggio di RegNetY su ResNet18 si amplia sotto shift, e si somma a quello della ricetta (RealWaste 0.582 contro 0.492 per ResNet18 sotto `acq_mild`). Plastic sotto l'acquisizione più dura resta il punto debole residuo.